



Análise de Lifting de Dados 2D para 3D para Reconhecimento de Gestos

Proposta de TCC - Davi Baechtold

Investigando como a transformação 2D→3D pode aprimorar o reconhecimento de gestos em aplicações de visão computacional

Motivação do Projeto

Desafios Atuais

Reconhecimento de gestos em cenários reais enfrenta limitações significativas com abordagens puramente 2D:

- Perda de informação de profundidade
- Vulnerabilidade a oclusões
- Instabilidade temporal



O lifting 2D→3D emerge como uma solução promissora para superar essas limitações, oferecendo representações espaciais mais robustas.

Objetivos da Pesquisa



Comparação 2D vs 3D

Avaliar o desempenho de classificadores temporais usando sequências 2D versus 3D pós-lifting



Métricas de Estimação

Analisar MPJPE, PA-MPJPE e impacto na acurácia de classificação de gestos



Sinais Auxiliares

Integrar depth monocular, segmentação humana e múltiplas visões no processo de lifting



Protótipo Real

Desenvolver demonstração em tempo real usando webcam Logitech C922 Pro Stream

Questões de Pesquisa

1 Quando o lifting 2D→3D oferece vantagens?

Identificar condições específicas onde a transformação reduz ambiguidades e melhora a classificação

3 Sinais auxiliares ajudam em cenários desafiadores?

Avaliar contribuição de depth monocular e segmentação em oclusões e fundos complexos

2 Qual o ganho de múltiplas câmeras?

Comparar qualidade entre lifting single-view (LiftPose3D) versus multi-view (Transformer)

4 Como facilitar transferência entre domínios?

Explorar domain adaptation linear para adaptar modelos a novos ambientes com poucos dados

Pipeline Metodológico



Extração de Keypoints 2D

MediaPipe para pose e mãos a partir de vídeos ou webcam em tempo real



Lifting 2D→3D

Single-view (LiftPose3D-like MLP/TCN) ou Multi-view (Transformer fusion)



Enriquecimento Opcional

Depth monocular (MiDaS) e segmentação humana para maior robustez



Classificação Temporal

Transformer encoder ou LSTM sobre sequências 2D vs 3D vs 3D+auxiliares




Avaliação

Testes offline com manifests e validação em tempo real com webcam C922

Abordagens de Lifting

Single-View (LiftPose3D)



- Joints 2D normalizados por root e escala
- MLP/TCN com camadas residuais
- Domain adaptation via mapeamento linear
- Perda MPJPE e variante PA-MPJPE

Multi-View (MPL-like)



- Múltiplas câmeras sincronizadas
- Fusão via Transformer de poses 2D
- Supervisão com 3D ground truth
- Dados sintéticos AMASS para treinamento

Métricas de Avaliação



Estimação 3D

- **MPJPE:** Distância euclidiana média por articulação
- **PA-MPJPE:** MPJPE após alinhamento Procrustes
- **MPVE:** Média por vértice em malha (opcional)



Classificação de Gestos

- **Acurácia e F1 macro**
- Matriz de confusão detalhada
- Curva Precision-Recall por classe



Performance Temporal

- **Latência média:** ms/frame no demo
- Processamento em CPU (C922)
- Meta: ≤ 60 ms/frame

Protocolo Experimental



Datasets e Implementação

Dados de Treinamento

- **20BN-Jester:** Gestos manuais públicos
- **SHREC/NTU RGB+D:** Referência de protocolo
- **Coleta própria:** Gestos alvo com C922
- **Dados sintéticos:** AMASS para pares 2D↔3D

Formato de Dados

Manifestos .csv com path,label apontando para arquivos .npz contendo sequências de keypoints normalizados

Scripts de Implementação

```
scripts/  
├── train_lifter.py  
├── lift_sequences.py  
├── evaluate_3d_metrics.py  
└── depth_segment_features.py
```

```
src/models/  
├── lifter.py  
├── temporal_tcn.py  
└── transformer_encoder.py
```

```
configs/  
└── lifter.yaml
```



Datasets para Lifting 2D→3D



Human3.6M

- 3.6 milhões de frames de 11 atores
- 17 ações do dia a dia gravadas por 4 câmeras
- Padrão-ouro para avaliação de HPE 3D
- Ideal para treinar lifter e calcular MPJPE/PA-MPJPE




CMU Panoptic Studio

- Mais de 30 câmeras HD em domo geodésico
- Cenas de interações sociais complexas
- Excelente para análise multi-view robusta
- Ideal para estudos de oclusão severa



AMASS (Archive of Motion Capture)

- Centenas de horas de dados MoCap unificados
- Formato SMPL para geração de dados sintéticos
- Permite treinar lifter para qualquer configuração
- Base para domain adaptation



Datasets para Classificação de Gestos



20BN-Jester Dataset

- Mais de 148.000 vídeos curtos
- 27 gestos de mão predefinidos
- Gestos dinâmicos desafiadores
- Dataset principal para benchmark (O1)
- Ideal para comparar classificadores 2D vs 3D

SHREC (Shape Retrieval Contest)

- Focado em reconhecimento de gestos 3D
- Dados de profundidade (Kinect) e keypoints 3D
- Referência para validação de qualidade
- Testes de pipeline completo

Coleta Própria com C922

- Gestos específicos do projeto
- Ambiente controlado para testes
- Validação de domain adaptation
- Demonstração em tempo real

A tabela abaixo resume os principais aspectos de cada dataset:

20BN-Jester	Vídeos 2D (gestos dinâmicos)	Benchmark de classificação, Comparação 2D vs 3D	O1
SHREC	Dados de profundidade 3D, keypoints	Validação de qualidade, Teste de pipeline completo	O1, O2
Coleta Própria com C922	Vídeos de webcam (gestos específicos)	Testes em ambiente controlado, Validação de domain adaptation, Demonstração	O3, O4

Impacto e Próximos Passos



Aplicações Industriais

HCI/XR, robótica colaborativa, direção assistida por gestos e análise de movimento ocupacional



Contribuição Científica

Análise sistemática de lifting 2D→3D para gestos com validação em cenários reais



Impacto Prático

Pipeline otimizado para CPU, acessível e adaptável a diferentes domínios de aplicação

❏ **Critérios de Sucesso:** Aumento de F1 macro ao migrar 2D→3D, MPJPE competitivo com baselines, e latência $\leq 60\text{ms/frame}$ no demo em tempo real