

PLANO DE PROJETO

ARQUITETURA EFICIENTE PARA ESTIMAÇÃO DE POSE COMPLETA (FULLBODY) EM AMBIENTE VEICULAR ATRAVÉS DE *LIFTING* 2D-PARA-3D

Integrante: Davi Baechtold Campos

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Assinaturas:

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Discente: Davi Baechtold Campos

Curitiba, 26 de setembro de 2025

Sumário

1	RESUMO	2
2	INTRODUÇÃO	2
2.1	Pergunta de Pesquisa	2
2.2	Objetivo Geral	2
2.3	Objetivos Específicos	2
3	DETALHAMENTO DO PROBLEMA	3
4	METODOLOGIA	3
4.1	Diagrama em blocos do sistema	3
4.2	Arquitetura Proposta	3
4.3	Datasets	4
4.4	Métricas de Avaliação	4
5	ARQUITETURA TÉCNICA	4
5.1	Módulo 1: Detecção 2D Multimodal	4
5.2	Módulo 2: Fusão Temporal e Lifting 3D	4
5.3	Estratégia de Eficiência	4
6	CRONOGRAMA	5
7	RESULTADOS ESPERADOS	5
8	REFERÊNCIAS	5

1 RESUMO

Este projeto propõe o desenvolvimento de uma arquitetura eficiente para estimação de pose completa (*fullbody*) em ambiente veicular utilizando técnicas de *2D-to-3D lifting* baseadas em keypoints. O *lifting* refere-se ao processo de inferir coordenadas tridimensionais (3D) a partir de pontos bidimensionais (2D) detectados em imagens, resolvendo a ambiguidade de profundidade através de modelos de aprendizado profundo. O foco principal será no desenvolvimento de métodos robustos para detecção e lifting de keypoints corporais, com expansão posterior para face e mãos. A pesquisa aborda a questão fundamental de como construir uma arquitetura computacionalmente eficiente que integre corpo, face e mãos em um sistema unificado de monitoramento veicular. O projeto utilizará pré-treinamento com datasets públicos e validação no Drive&Act dataset para cenários automotivos específicos.

Palavras-chave: fullbody pose estimation; keypoints; arquitetura eficiente; ambiente veicular.

2 INTRODUÇÃO

A estimação de pose completa (*fullbody*) em tempo real representa um desafio crítico para sistemas de monitoramento veicular inteligente. Diferente de aplicações gerais, o contexto automotivo demanda eficiência computacional e robustez a oclusões específicas do ambiente de cabine.

2.1 Pergunta de Pesquisa

Research Question: Como construir uma arquitetura computacionalmente eficiente para estimação de pose completa (*fullbody*) que integre corpo, face e mãos de forma unificada em ambiente veicular restrito?

2.2 Objetivo Geral

Desenvolver e avaliar uma arquitetura eficiente para estimação de pose completa utilizando keypoints, com foco inicial em corpo e expansão progressiva para face e mãos.

2.3 Objetivos Específicos

- Implementar pipeline robusto para detecção de keypoints corporais 2D.
- Desenvolver módulo de lifting 2D-para-3D otimizado para corpo.
- Expandir arquitetura para integração de keypoints de face e mãos.
- Avaliar eficiência computacional e precisão da arquitetura unificada.

- Validar sistema em cenários automotivos reais (Drive&Act dataset).

3 DETALHAMENTO DO PROBLEMA

A estimação de pose completa em ambiente veicular apresenta desafios únicos:

- **Complexidade multimodal:** Integração eficiente de corpo (17 keypoints), face (68+ keypoints) e mãos (21 keypoints cada).
- **Oclusões específicas:** Volante oculta mãos, painel limita visão corporal, postura de condução restringe movimentos.
- **Eficiência computacional:** Necessidade de processamento em tempo real com recursos limitados.
- **Variabilidade temporal:** Gestos e mudanças posturais rápidas durante condução.

4 METODOLOGIA

4.1 Diagrama em blocos do sistema

A Figura 1 apresenta a visão geral do sistema e a interação entre os módulos propostos.




Figura 1: Diagrama em blocos do sistema proposto.

4.2 Arquitetura Proposta

- **Backbone compartilhado:** Extrator de features eficiente para múltiplas modalidades.
- **Heads especializados:** Detectores específicos para corpo, face e mãos.
- **Fusão temporal:** Módulo de atenção para consistência inter-frame.
- **Lifting unificado:** Arquitetura baseada em Transformers para lifting conjunto.

4.3 Datasets

- **Pré-treinamento 2D:** COCO, MPII, 300W (face), FreiHAND (mãos).
- **Lifting 3D:** Human3.6M, AMASS (dados sintéticos).
- **Validação automotiva:** Drive&Act dataset.
- **Dados sintéticos:** Geração de cenários de cabine com SMPL + renderização.

4.4 Métricas de Avaliação

- **Precisão:** MPJPE para corpo, face e mãos separadamente.
- **Eficiência:** FPS, latência, uso de memória.
- **Robustez:** Performance sob oclusões e variações de iluminação.

5 ARQUITETURA TÉCNICA

5.1 Módulo 1: Detecção 2D Multimodal

- **Backbone:** ResNet/EfficientNet compartilhado.
- **Head Corpo:** Adaptação do RTMPose para 17 keypoints.
- **Head Face:** Detector facial baseado em MediaPipe (68 pontos).
- **Head Mãos:** Detecção de 21 keypoints por mão.

5.2 Módulo 2: Fusão Temporal e Lifting 3D

- **Encoder temporal:** Transformer com janela deslizante (16-32 frames).
- **Fusão multimodal:** Atenção cruzada entre corpo, face e mãos.
- **Decoder 3D:** Regressão para coordenadas 3D unificadas.

5.3 Estratégia de Eficiência

- **Compartilhamento de features:** Backbone único para todas modalidades.
- **Quantização:** INT8 para deploy em hardware embarcado.
- **Pruning adaptativo:** Remoção de conexões menos relevantes.
- **Processamento hierárquico:** Priorização de corpo ζ face ζ mãos conforme disponibilidade computacional.

6 CRONOGRAMA

Tabela 1: Cronograma detalhado do projeto.

Fase	Atividades	Mês	Entrega
1	Setup + dataset prep + body 2D detector	1-2	Pipeline corpo 2D
2	Body lifting 3D + baseline em Drive&Act	3-4	Resultados corpo 3D
3	Paper corpo: escrita + submissão	5	Publicação submetida
4	Integração face: detector + lifting	6-7	Módulo face funcional
5	Integração mãos + arquitetura unificada	8-9	Sistema full-body
6	Otimização + validação + TCC final	10-12	TCC completo

7 RESULTADOS ESPERADOS

- **Precisão:** MPJPE $\leq$ 50mm para corpo em Drive&Act.
- **Eficiência:** 20 FPS para fullbody em GPU embarcada.
- **Robustez:** $\leq$ 20% degradação sob oclusões típicas de cabine.
- **Publicação:** Paper aceito em conferência de visão computacional.

8 REFERÊNCIAS

Referências

- 1 MARTINEZ, J. et al. **A simple yet effective baseline for 3D human pose estimation**. In: ICCV. 2017.
- 2 ISKAKOV, K. et al. **Learnable triangulation of human pose**. In: ICCV. 2019.
- 3 MARTIN, M. et al. **Drive&Act: A Multi-Modal Dataset for Fine-Grained Driver Behavior Recognition**. In: ICCV. 2019.
- 4 JIANG, T. et al. **RTMPose: Real-Time Multi-Person Pose Estimation**. arXiv:2303.07399, 2023.
- 5 VASWANI, A. et al. **Attention is all you need**. In: NeurIPS. 2017.

6 ZHANG, C. et al. **LiftPose3D: transforming 2D poses to 3D in real-time.**
arXiv:2008.02945, 2020.