

PLANO DE PROJETO

MONITORAMENTO DE POSTURA DE OCUPANTES EM CABINE VEICULAR ATRAVÉS DE *LIFTING* 2D-PARA-3D

Integrante: Davi Baechtold Campos

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Coorientador: Prof. Dr. Alessandro Zimmer

Assinaturas:

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Curitiba, 25 de setembro de 2025

Sumário

1	RESUMO	2
2	INTRODUÇÃO	2
2.1	Relevância do problema	2
2.2	Desenvolvimento proposto	2
2.3	Abordagem Comparativa	2
2.4	Contribuição Científica	3
3	DETALHAMENTO DO PROBLEMA	3
4	TRABALHO A SER DESENVOLVIDO	3
4.1	Diagrama em blocos do sistema	4
5	TECNOLOGIAS QUE SERÃO UTILIZADAS	4
6	METODOLOGIA EXPERIMENTAL	5
6.1	Datasets e Métricas	5
6.2	Protocolo Experimental	5
7	VALIDAÇÃO E CRITÉRIOS DE SUCESSO	5
7.1	Hipóteses a Serem Testadas	5
7.2	Critérios Quantitativos de Aceite	6
8	ANÁLISE DOS RISCOS	6
9	CRONOGRAMA DO PROJETO	6
10	CONCLUSÃO	7
11	REFERÊNCIAS	7

1 RESUMO

Este projeto propõe o desenvolvimento de um sistema para monitoramento da postura de ocupantes em tempo real no interior de veículos. O problema central é a dificuldade de obter informações tridimensionais (3D) precisas sobre a posição dos ocupantes usando hardware de baixo custo. A solução consiste em uma abordagem de *2D-to-3D lifting*, que utiliza câmeras 2D convencionais para, primeiramente, detectar os pontos-chave (articulações) do corpo em duas dimensões e, em seguida, inferir a profundidade para reconstruir a pose completa em 3D. Serão investigadas tecnologias como Redes Neurais Convolucionais (CNNs) para a detecção 2D e modelos de aprendizado profundo para o *lifting*, com foco na fusão de dados de múltiplas câmeras e na análise de profundidade monocular para superar os desafios do ambiente veicular, como oclusões e iluminação variável.

Palavras-chave: Visão computacional. Estimação de pose 3D. Segurança veicular. Aprendizado profundo.

2 INTRODUÇÃO

A motivação para este trabalho reside na crescente demanda por sistemas de segurança automotiva inteligentes e adaptativos. Conhecer a postura exata do motorista e dos passageiros em tempo real permite otimizar o acionamento de sistemas de segurança, como airbags e cintos de segurança, e desenvolver novas interfaces homem-máquina.

2.1 Relevância do problema

Sistemas de segurança passiva atuais operam com base em suposições genéricas sobre a posição dos ocupantes. Um sistema que monitora a postura real pode reduzir drasticamente o risco de lesões ao adaptar a resposta dos dispositivos de segurança à situação específica do ocupante, representando um avanço significativo na segurança veicular.

2.2 Desenvolvimento proposto

Será desenvolvido um *pipeline* de software que recebe o fluxo de vídeo de câmeras 2D instaladas na cabine e gera uma representação esquelética 3D da postura dos ocupantes. Esta informação 3D, rica em detalhes, pode ser consumida por sistemas de controle do veículo para tomada de decisões inteligentes em tempo real.

2.3 Abordagem Comparativa

Este trabalho realizará uma análise comparativa quantitativa entre diferentes estratégias de *lifting* 2D-para-3D para determinar a abordagem mais robusta para o ambiente veicular:

- **Baseline Monocular:** *Lifting* utilizando os dados de apenas uma câmera.
- **Fusão Multi-view:** Fusão de dados de múltiplas câmeras sincronizadas para resolver oclusões.
- **Lifting com Profundidade:** Incorporação de mapas de profundidade estimados por um modelo monocular (ex: Depth Anything v2) para enriquecer a informação de entrada.

O objetivo é quantificar o ganho de precisão de cada abordagem no contexto específico de cabine veicular.

2.4 Contribuição Científica

Este projeto visa produzir uma contribuição mensurável para a área de estimação de pose em ambientes restritos. A comparação sistemática entre abordagens, com métricas objetivas em um contexto veicular, tem potencial para resultar em uma publicação científica, elevando o impacto do trabalho além dos requisitos de graduação.

3 DETALHAMENTO DO PROBLEMA

O problema a ser resolvido é a estimação precisa da pose 3D de ocupantes em um ambiente veicular confinado e dinâmico, utilizando apenas câmeras 2D. Os principais desafios técnicos incluem:

- **Oclusões severas:** O volante, o painel, os bancos e os próprios membros do ocupante frequentemente ocultam articulações cruciais, tornando a detecção 2D e a inferência 3D ambíguas.
- **Ambiguidade 2D-para-3D:** Múltiplas poses 3D podem resultar na mesma projeção 2D. O sistema precisa de conhecimento contextual e temporal para resolver essa ambiguidade.
- **Condições de iluminação adversas:** A iluminação dentro da cabine pode variar drasticamente (dia, noite, sombras, luz solar direta), o que afeta o desempenho dos detectores de pose 2D.
- **Processamento em tempo real:** Para ser eficaz em aplicações de segurança, o sistema precisa operar com baixa latência em hardware embarcado de custo limitado.

4 TRABALHO A SER DESENVOLVIDO

A solução funcional será um sistema modular que processa fluxos de vídeo e gera coordenadas 3D para as articulações dos ocupantes. O projeto será decomposto nos seguintes módulos funcionais:

- **Módulo 1 - Aquisição e Sincronização de Imagens:** Responsável por capturar imagens de múltiplas câmeras e sincronizá-las temporalmente.
- **Módulo 2 - Extração de Features 2D:** Utiliza modelos pré-treinados para extrair informações de cada imagem.
 - **2.1 - Detecção de Pose 2D:** Detecta os keypoints 2D (ex: MediaPipe, RTMPose).
 - **2.2 - Estimação de Profundidade:** Gera um mapa de profundidade monocular (ex: Depth Anything v2).
- **Módulo 3 - Fusão Multimodal e *Lifting* 3D:** Núcleo do projeto, responsável por combinar as features e estimar as coordenadas 3D.
 - **3.1 - Fusão de Features:** Combina keypoints 2D, mapas de profundidade e informações de múltiplas vistas usando uma arquitetura baseada em Transformers.
 - **3.2 - Regressão da Pose 3D:** Estima as coordenadas 3D finais a partir das features fundidas.
- **Módulo 4 - Visualização e Avaliação:** Renderiza o esqueleto 3D e calcula métricas de erro para avaliação de desempenho.

4.1 Diagrama em blocos do sistema

A Figura 1 apresenta a visão geral do sistema e a interação entre os módulos propostos.




Figura 1: Diagrama em blocos do sistema proposto.

5 TECNOLOGIAS QUE SERÃO UTILIZADAS

- **Linguagem de programação:** Python.
- **Framework de deep learning:** PyTorch.
- **Bibliotecas de visão computacional:** OpenCV, NumPy.
- **Modelos Específicos:**
 - **Detecção de Pose 2D:** MediaPipe Holistic ou RTMPose.
 - **Estimação de Profundidade:** Depth Anything v2.

- **Lifting 3D:** Arquitetura baseada em Transformers (ex: PoseFormer) adaptada para fusão multimodal.
- **Fusão Multi-view:** Estratégia inspirada em triangulação aprendível (*learnable triangulation*).
- **Hardware:** Câmeras USB e GPU (NVIDIA) para aceleração.

6 METODOLOGIA EXPERIMENTAL

6.1 Datasets e Métricas

- **Dados Sintéticos:** Geração de dados de cabine veicular utilizando o pipeline AMASS e o modelo SMPL para obter *ground truth* 3D preciso.
- **Dados Reais:** Coleta controlada em ambiente de simulação veicular com múltiplas câmeras sincronizadas para validação.
- **Métricas de Avaliação Principais:**
 - **MPJPE (Mean Per Joint Position Error):** Distância euclidiana média entre as articulações estimadas e as reais.
 - **PA-MPJPE (Procrustes Aligned MPJPE):** MPJPE após alinhamento rígido (rotação, translação, escala) para medir o erro de forma.

6.2 Protocolo Experimental

Cada uma das três abordagens (monocular, multi-view, com profundidade) será avaliada sob condições controladas para testar sua robustez, incluindo:

- Diferentes níveis de oclusão (pelo volante, painel, e auto-occlusão).
- Variações de iluminação (diurna, noturna, sombras).
- Poses típicas de condução e de interação com o painel.

7 VALIDAÇÃO E CRITÉRIOS DE SUCESSO

7.1 Hipóteses a Serem Testadas

1. A fusão multi-view reduz o MPJPE em pelo menos 15% em comparação com a baseline monocular em cenários com oclusão.

2. A incorporação de mapas de profundidade melhora a robustez do modelo monocular, reduzindo a ambiguidade de escala e o erro em profundidade.
3. O sistema proposto atinge uma precisão comparável ao estado da arte em datasets públicos de referência (ex: Human3.6M).

7.2 Critérios Quantitativos de Aceite

- **Precisão Mínima:** Atingir um PA-MPJPE inferior a 50mm no dataset Human3.6M.
- **Robustez à Oclusão:** Manter uma degradação de performance inferior a 30% em cenários com até 3 articulações ocluídas.
- **Performance de Inferência:** Atingir uma taxa de processamento superior a 15 FPS em uma GPU de gama média (ex: NVIDIA RTX 3060).

8 ANÁLISE DOS RISCOS

- **Risco Técnico 1 (Alto):** Baixa precisão em casos de oclusão severa. **Mitigação:** Foco na fusão de dados de múltiplas câmeras e na incorporação de profundidade para obter informações complementares.
- **Risco Técnico 2 (Alto):** Sincronização imprecisa entre múltiplas câmeras, degradando a performance da fusão multi-view. **Mitigação:** Implementar calibração temporal robusta (ex: usando um sinal luminoso) e algoritmos de correção de *drift*.
- **Risco de Dados (Médio):** Dificuldade em obter dados 3D reais anotados para o ambiente veicular. **Mitigação:** Estratégia híbrida, com pré-treinamento em dados sintéticos (AMASS) e ajuste fino (*fine-tuning*) em um conjunto menor de dados reais anotados.
- **Risco de Projeto (Médio):** Atingir a performance de tempo real em hardware embarcado. **Mitigação:** Iniciar o desenvolvimento em desktop com GPU e, posteriormente, focar em técnicas de otimização de modelos (quantização, *pruning*).

9 CRONOGRAMA DO PROJETO

O cronograma descreve as fases do projeto, incluindo desenvolvimento, testes e documentação, conforme apresentado na Tabela 1.

Tabela 1: Cronograma detalhado com marcos de entrega.

Fase	Atividades Principais	Período (Est.)	Marco de Entrega
1	Revisão bibliográfica, definição de arquitetura e setup do ambiente de desenvolvimento	Mês 1 - Mês 2	Documento de arquitetura e ambiente configurado
2	Implementação do pipeline de dados (sintéticos e reais) e do detector 2D	Mês 2 - Mês 3	Pipeline de extração de features 2D funcional
3	Desenvolvimento do modelo de <i>lifting</i> 3D (Baseline Monocular)	Mês 3 - Mês 5	Modelo baseline treinado e avaliado
4	Implementação da fusão multi-view e do <i>lifting</i> com profundidade	Mês 5 - Mês 7	Modelos comparativos implementados
5	Integração, testes comparativos e otimização dos modelos	Mês 8 - Mês 9	Relatório de resultados comparativos
6	Escrita do relatório final, preparação da apresentação e do artigo	Mês 10 - Mês 12	Versão final do TCC e submissão do artigo

10 CONCLUSÃO

Este projeto visa desenvolver uma solução de baixo custo e alta precisão para o monitoramento de postura de ocupantes em veículos, abordando um problema relevante para a segurança automotiva. A estratégia de desenvolvimento modular, focada na comparação de técnicas de *2D-to-3D lifting* com fusão de dados de múltiplas fontes, permitirá uma investigação aprofundada e a criação de uma solução robusta com potencial para contribuição científica e tecnológica.

11 REFERÊNCIAS

Referências

- 1 ISKAKOV, Karim et al. **Learnable triangulation of human pose**. In: IEEE/CVF INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2019, Seoul. *Proceedings...* Seoul: IEEE, 2019. p. 7718-7727.
- 2 MARTINEZ, Julieta et al. **A simple yet effective baseline for 3d human pose estimation**. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017, Venice. *Proceedings...* Venice: IEEE, 2017. p. 2640-2649.
- 3 RANFTL, René et al. **Towards robust monocular depth estimation: mixing datasets for zero-shot cross-dataset transfer**. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 44, n. 3, p. 1623-1637, 2020.

- 4 YANG, Lihe et al. **Depth anything: unleashing the power of large-scale unlabeled data.** *arXiv preprint arXiv:2401.10891*, 2024. Disponível em: [;https://arxiv.org/abs/2401.10891](https://arxiv.org/abs/2401.10891). Acesso em: 25 set. 2025.
- 5 ZHANG, Chen et al. **LiftPose3D: a deep learning-based approach for transforming 2D poses to 3D in real-time.** *arXiv preprint arXiv:2008.02945*, 2020. Disponível em: [;https://arxiv.org/abs/2008.02945](https://arxiv.org/abs/2008.02945). Acesso em: 25 set. 2025.
- 6 ZHANG, Jiawei et al. **MPL: lifting 3D human pose from multi-view priors learned with self-supervision.** *arXiv preprint arXiv:2308.11718*, 2023. Disponível em: [;https://arxiv.org/abs/2308.11718](https://arxiv.org/abs/2308.11718). Acesso em: 25 set. 2025.
- 7 VASWANI, Ashish et al. **Attention is all you need.** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. *Proceedings...* Long Beach: NIPS, 2017. p. 5998-6008.