

PLANO DE PROJETO

ARQUITETURA EFICIENTE PARA ESTIMAÇÃO DE POSE COMPLETA (*FULL-BODY*) EM AMBIENTE VEICULAR ATRAVÉS DE *LIFTING* 2D-PARA-3D

Integrante: Davi Baechtold Campos

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Coorientador: Prof. Dr. Alessandro Zimmer

Assinaturas:

Orientador: Prof. Dr. Alceu de Souza Brito Junior

Coorientador: Prof. Dr. Alessandro Zimmer

Curitiba, 30 de setembro de 2025

Sumário

1	RESUMO	1
2	INTRODUÇÃO	1
2.1	Motivação	1
2.2	Pergunta de Pesquisa	1
2.3	Objetivo Geral	2
2.4	Objetivos Específicos	2
2.5	Estrutura do Documento	2
3	DETALHAMENTO DO PROBLEMA	2
4	ESTADO DA ARTE	3
4.1	Soluções Existentes	3
4.2	Análise Crítica	3
5	TRABALHO A SER DESENVOLVIDO	3
5.1	Diagrama em blocos do sistema	3
5.2	Arquitetura Proposta	3
5.3	Módulos Funcionais	4
5.3.1	Módulo 1: Aquisição	4
5.3.2	Módulo 2: Detecção 2D	4
5.3.3	Módulo 3: Fusão e Lifting 3D	4
5.3.4	Módulo 4: Visualização	4
6	TECNOLOGIAS E DATASETS	4
6.1	Tecnologias de Implementação	4
6.2	Datasets para Treinamento e Validação	4
7	PROCEDIMENTOS DE TESTE E VALIDAÇÃO	5
7.1	Métricas de Avaliação	5
7.2	Critérios de Aceite	5
8	ANÁLISE DE RISCOS	5
9	CRONOGRAMA DO PROJETO	5
10	CONCLUSÃO	6
11	REFERÊNCIAS	6

1 RESUMO

Este projeto propõe o desenvolvimento de uma arquitetura eficiente para estimação de pose completa (*full-body*) em ambiente veicular utilizando técnicas de *2D-to-3D lifting* baseadas em *keypoints*. O *lifting* refere-se ao processo de inferir coordenadas tridimensionais (3D) a partir de pontos bidimensionais (2D) detectados em imagens, resolvendo a ambiguidade de profundidade através de modelos de aprendizado profundo. O foco principal será no desenvolvimento de métodos robustos para detecção e *lifting* de *keypoints* corporais, com expansão posterior para face e mãos. A pesquisa aborda a questão fundamental de como construir uma arquitetura computacionalmente eficiente que integre corpo, face e mãos em um sistema unificado de monitoramento veicular. O projeto utilizará pré-treinamento com datasets públicos, incluindo o dataset do RTMPose para *2D pose keypoints*, e validação no Drive&Act dataset para cenários automotivos específicos.

Palavras-chave: Estimação de Pose *Full-Body*; *Keypoints*; Arquitetura Eficiente; Ambiente Veicular; *2D-to-3D Lifting*.

2 INTRODUÇÃO

A estimação de pose completa (*full-body*) em tempo real representa um desafio crítico para sistemas de monitoramento veicular inteligente. Diferente de aplicações gerais, o contexto automotivo demanda eficiência computacional e robustez a oclusões específicas do ambiente de cabine.

2.1 Motivação

A crescente necessidade de sistemas de segurança e monitoramento em veículos torna a estimação de pose uma área de pesquisa relevante. A capacidade de entender a postura dos ocupantes pode melhorar a segurança e a experiência do usuário, sendo um componente essencial para a próxima geração de Sistemas Avançados de Assistência ao Condutor (ADAS).

2.2 Pergunta de Pesquisa

Research Question: Como construir uma arquitetura computacionalmente eficiente para estimação de pose completa (*full-body*) que integre corpo, face e mãos de forma unificada em ambiente veicular restrito?

2.3 Objetivo Geral

Desenvolver e avaliar uma arquitetura eficiente para estimação de pose completa utilizando *keypoints*, com foco inicial em corpo e expansão progressiva para face e mãos.

2.4 Objetivos Específicos

- Implementar um pipeline robusto para detecção de *keypoints* corporais 2D.
- Desenvolver um módulo de *lifting* 2D-para-3D otimizado para corpo.
- Expandir a arquitetura para integração de *keypoints* de face e mãos.
- Avaliar a eficiência computacional e a precisão da arquitetura unificada.
- Validar o sistema em cenários automotivos realistas utilizando o Drive&Act dataset.

2.5 Estrutura do Documento

Este documento está estruturado da seguinte forma: a Seção 3 detalha o problema a ser resolvido. A Seção 4 discute o estado da arte. A Seção ?? descreve a solução proposta. As tecnologias, procedimentos de teste, riscos, cronograma, contribuições e resultados esperados são apresentados nas seções subsequentes, finalizando com as referências.

3 DETALHAMENTO DO PROBLEMA

A estimação de pose completa em ambiente veicular apresenta desafios únicos que não são comumente encontrados em outros cenários:

- **Complexidade Multimodal:** Integração eficiente de corpo (17 *keypoints*), face (68+ *keypoints*) e mãos (21 *keypoints* cada).
- **Oclusões Específicas:** O volante oculta mãos e torso, o painel limita a visão corporal, e a própria postura de condução restringe os movimentos e aumenta a auto-occlusão.
- **Eficiência Computacional:** Necessidade de processamento em tempo real com recursos de hardware limitados, típicos de sistemas embarcados.
- **Variabilidade Temporal:** Gestos e mudanças posturais rápidas durante a condução exigem que o modelo tenha consistência temporal.

4 ESTADO DA ARTE

Esta seção apresenta um levantamento das soluções existentes para o problema de estimação de pose, incluindo uma análise crítica das abordagens mais relevantes.

4.1 Soluções Existentes

Diversas abordagens têm sido propostas para a estimação de pose, incluindo métodos baseados em redes neurais convolucionais (CNNs) e técnicas de aprendizado profundo. A maioria dessas soluções se concentra na detecção de *keypoints* em imagens 2D, mas enfrenta desafios em ambientes dinâmicos e com oclusões.

4.2 Análise Crítica

As melhores soluções atuais, como RTMPose e LiftPose3D, demonstram eficácia em ambientes controlados, mas apresentam limitações em cenários do mundo real, como veículos, onde a oclusão e a variabilidade de iluminação são comuns. A proposta deste projeto visa superar essas limitações através de uma arquitetura unificada que integra múltiplas modalidades.

5 TRABALHO A SER DESENVOLVIDO

Nesta seção, uma descrição funcional da solução proposta será feita.

5.1 Diagrama em blocos do sistema

A Figura 1 apresenta a visão geral do sistema e a interação entre os módulos propostos.




Figura 1: Diagrama em blocos do sistema proposto.

5.2 Arquitetura Proposta

- **Backbone compartilhado:** Extrator de features eficiente para múltiplas modalidades.
- **Heads especializados:** Detectores específicos para corpo, face e mãos.
- **Fusão temporal:** Módulo de atenção para consistência inter-frame.
- **Lifting unificado:** Arquitetura baseada em Transformers para lifting conjunto.

5.3 Módulos Funcionais

Cada módulo funcional será descrito individualmente, incluindo a implementação e as tecnologias utilizadas.

5.3.1 Módulo 1: Aquisição

Responsável pela captura de imagens das câmeras. Será implementado em Python utilizando bibliotecas como OpenCV.

5.3.2 Módulo 2: Detecção 2D

Utilizará modelos pré-treinados para detectar keypoints corporais em imagens 2D. A implementação será feita em PyTorch, utilizando o dataset do RTMPose para pré-treinamento.

5.3.3 Módulo 3: Fusão e Lifting 3D

Integrará os dados 2D e realizará o lifting para 3D. Este módulo será desenvolvido utilizando técnicas de aprendizado profundo.

5.3.4 Módulo 4: Visualização

Responsável pela apresentação dos resultados. Será implementado em uma interface gráfica utilizando Tkinter.

6 TECNOLOGIAS E DATASETS

6.1 Tecnologias de Implementação

- **Linguagem:** Python 3.10+.
- **Frameworks:** PyTorch para os modelos de *deep learning*.
- **Bibliotecas:** OpenCV para processamento de imagem, NumPy para operações numéricas.
- **Modelos Base:** Arquiteturas como RTMPose, EfficientNet e Transformers serão a base para os módulos.

6.2 Datasets para Treinamento e Validação

- **Pré-treinamento 2D:** COCO, MPII, 300W (face), FreiHAND (mãos).
- **Treinamento do Lifting 3D:** Human3.6M, AMASS (para dados sintéticos).
- **Validação Automotiva:** Drive&Act dataset.

7 PROCEDIMENTOS DE TESTE E VALIDAÇÃO

7.1 Métricas de Avaliação

- **Precisão:** MPJPE (Mean Per Joint Position Error) e PA-MPJPE (Procrustes Aligned MPJPE) para corpo, face e mãos separadamente.
- **Eficiência:** FPS (Frames Per Second), latência de inferência (ms) e uso de memória (MB).
- **Robustez:** Avaliação da degradação da precisão sob cenários de oclusão e variações de iluminação.

7.2 Critérios de Aceite

- **Precisão:** Atingir um MPJPE inferior a 50mm para o corpo no dataset Drive&Act.
- **Eficiência:** Alcançar uma taxa de inferência de, no mínimo, 20 FPS para o sistema *full-body* em uma GPU de gama média.

8 ANÁLISE DE RISCOS

- **Complexidade da Arquitetura (Alto):** A integração de múltiplas partes do corpo é complexa. **Mitigação:** Desenvolvimento incremental (corpo -> face -> mãos), com validação em cada etapa.
- **Limitações Computacionais (Médio):** Atingir tempo real pode ser desafiador. **Mitigação:** Foco em arquiteturas eficientes (e.g., EfficientNet), compartilhamento de *backbone* e técnicas de otimização como quantização.
- **Qualidade dos Dados (Médio):** As anotações do Drive&Act podem ter limitações. **Mitigação:** Complementação com dados sintéticos gerados e calibrados para o ambiente de cabine.

9 CRONOGRAMA DO PROJETO

Descrição de todas as fases do projeto, incluindo a sequência de desenvolvimento de cada módulo, o tempo de desenvolvimento e as fases de teste e documentação.

Tabela 1: Cronograma detalhado do projeto.

Fase	Atividades	Período	Entrega
1	Setup + dataset prep + body 2D detector	set/2025 – out/2025	Pipeline corpo 2D
2	Body lifting 3D + baseline em Drive&Act	nov/2025 – dez/2025	Resultados corpo 3D
3	Integração face: detector + lifting	fev/2026 – mar/2026	Módulo face funcional
4	Integração mãos + arquitetura unificada	abr/2026 – mai/2026	Sistema full-body
5	Otimização + validação + TCC final	jun/2026 – ago/2026	TCC completo

10 CONCLUSÃO

Este projeto visa desenvolver uma arquitetura eficiente para estimação de pose completa (*full-body*) em ambiente veicular, abordando um problema relevante e inovador na área de visão computacional. A estratégia de desenvolvimento incremental, iniciando com *keypoints* corporais para uma publicação científica e expandindo para face e mãos, juntamente com o uso de datasets específicos como o Drive&Act, fornece uma base sólida para o desenvolvimento de uma solução robusta que contribuirá tanto para o avanço científico quanto para aplicações práticas em sistemas de monitoramento veicular.

11 REFERÊNCIAS

Referências

- 1 MARTINEZ, J. et al. **A simple yet effective baseline for 3D human pose estimation**. In: ICCV. 2017.
- 2 ISKAKOV, K. et al. **Learnable triangulation of human pose**. In: ICCV. 2019.
- 3 MARTIN, M. et al. **Drive&Act: A Multi-Modal Dataset for Fine-Grained Driver Behavior Recognition**. In: ICCV. 2019.
- 4 JIANG, T. et al. **RTMPose: Real-Time Multi-Person Pose Estimation**. arXiv:2303.07399, 2023.
- 5 VASWANI, A. et al. **Attention is all you need**. In: NeurIPS. 2017.
- 6 ZHANG, C. et al. **LiftPose3D: transforming 2D poses to 3D in real-time**. arXiv:2008.02945, 2020.